

Insta360 Hackthon

What about 3D screen mate

我们尝试了 3D 桌面伴侣，说实话，非常艰难。既然要做3D，那其中很重要的一点就是要真，那么人物建模、动画、语音、思考全都要真，这是非常困难的事，每一步都很难。

首先先说 3D 建模吧，我们直接调用的是 tripo 的 api key，这个平台是专门做 picture2model 的，输入了一张图之后，经过背景清洗、白模搭建、纹理贴图 and 骨架绑定之后，产生一个还原度比较高的模型（指比起其他平台而言），但是仍然存在以下问题：

1. 面部精度不够高：这是不可接受的，如果要做3D，要么完全不像，要么完全像，夹在中间看上去就很劣质
2. 人体模型出现畸变：我们遇到了肩膀两侧不一样宽的情况
3. 绑骨不精确：tripo 默认的骨骼数量太少，尤其是缺失了面部和手部的点位，导致后续动作跟随效果很差

说实话 3D 建模在我们的项目中只是流水线的一环，但是其实内部非常的复杂，想要做到游戏动画那样的动作精度，我觉得确实存在技术壁垒。像我们这样啥也不懂调用人家 api 的，成果能动起来就不错了。这一部分（模型搭建、骨架构建、动作捕捉、动作匹配）在游戏工业界是怎么做的，其实应该很有趣，也很复杂。

至于动作捕捉，我们依然用的是 mediapipe，现在想来，通过单目摄像头理解物体之间的遮挡情况，出现误差是很正常的。上次虽然也用了 mediapipe，但是只需要抓人脸，不需要做动作匹配，就没有意识到“精准识别骨骼点”离“正确理解骨骼点之间的空间关系”之间的巨大鸿沟。就比如说手掌翻面，正对相机、背对相机的骨骼点识别出来几乎是完全一致的；当双臂从下垂位向前扬起时，肘关节到手腕的骨骼长度变短，但是不明确深度信息的情况下，既可以是手臂向后也可以是向前。这或许说明通过关节点来建模人体结构，这个方案本身是不够精确的，更进一步，通过单个相机识别人体动作是不够精确的。

如果所有骨骼点的深度信息都正确，似乎就没毛了，相当于所有骨骼点之间的空间关系明确了。不过似乎通过单目相机还是做不到的。

捕捉到了人的动作之后，让它作用到模型身上，又是一个难关。第一关是骨骼点名称、数量不匹配，需要从骨骼点较多的动捕向骨骼点较少的 tripo 导出模型妥协，通过点的映射来建立关联；第二关是镜像问题，这可能是面的法向量匹配问题，主要体现在手掌翻动、手腕尺桡偏和肘关节屈伸，不知道为什么会出现两侧都错或者单侧出错的情况。这一点在骨骼点较多的 vrm 上情况会好很多，似乎证明了骨骼点数量与空间关系正确度之间的正相关关系。

接着我们希望接入一个 LLM 能让模型自主、拟人化的动起来，但是实现效果相当粗糙。我们的思路是建立一个动作库，通过调用 tool 的方式调用一个动作（等效于播放一个动画）。这个方案离实时响应的数字人就很远了，播放动画在时间角度上粒度太粗了，而且也不能精准的表述“人”的想法，更不用说要维护一个庞大动作库的难度（这倒是无所谓了，反正录入的几个有限的动作也是一坨）。如果后续想要实现比较灵动的模型运动，可能的方案是让模型直接输出所有骨骼点的运动，实现实时的、细微的运动控制。

当然想要“灵动”，面部表情，尤其是口型的匹配就很重要，而这一点又是困难无比。就这么说吧，mediapipe 抓人体总共50个点，抓脸有一百多个点，想要和模型上的骨骼点一一匹配简直难如登天，

很难想象游戏/电影工业界是如何完成的，每一帧都是微调过的？

除了视觉上的“像”以外，如果想要复刻一个人，声音像也很重要。这一点似乎已经很成熟了，通过输入一段语音+对应的文字，就能极高精度的模仿一个人的声音，但是这个说法没有求证过。而且单个词的发音不代表说话的节奏像，如果节奏也能那么好的匹配了，我想现在导航软件的语音导览不会那么生硬了。

比起视觉、听觉上的像以外，思想上的像要跑通会更简单一点，但是真正实现的难度可能反而要大得多。这不是技术问题，更像是一个哲学上的问题——我需要多少资料，能够重建出一个人的“灵魂”？给定30日内和所有人的聊天记录，我能够重建他的近期记忆；给定1年的聊天记录，我能大致理解他的性格习惯；但是就算给定了从出生那一刻到现在的每一秒的高清影像，真的能“逆向”出一个人的思想吗？更进一步的，即使我看到一个人的行为就能重建出他的思想，那么我真的能预测一个人下一步的行为吗？如果不能，是不是说明人的思想本身是“不可理解”的呢？这似乎进入机械唯物主义探讨的范畴了。

之前一段时间相当流行 女娲.skill，收集有关个人的资料，通过 llm 蒸馏后形成一个语言风格、思想方式都接近本人的 skill。或许应该试用一下。不过从思想实验的角度而言，llm 不可解释的黑盒属性又引入了一些变量。本项目中用聊天记录来“蒸馏”，相当于只是给了一个外部的第二人称视角，缺少第一人称和第三人称的资料补充，效果不好也是可以理解的。而且本项目采用的“蒸馏”方式可能还不如女娲.skill。

除了思想、声音和外形以外，一个能够实时调动这些模块，实时理解周围环境的大脑（小脑？）似乎也是当前 llm/世界模型 做不到的。当然以上关于“像”的讨论，是基于重建一个“一模一样”的数字人的理论探讨，现实中这个要求自然是过于严格的。